

这是一个非常明智的策略。要在几个小时内拿到30分（50%），我们必须**战略性放弃**那些需要死记硬背的“具体论文细节”（如题目46-60的分布式架构和特定游戏AI），全力攻克强化学习的**底层逻辑和核心算法**（前45题）。

前45题主要围绕四大板块：**基础概念**、**MC与TD的区别**、**DQN家族**、**Actor-Critic/PPO**。只要吃透这四块，你就能稳拿30分以上。

下面是为你定制的***“考前几小时极速提分指南”***。

第一板块：RL 基础概念 (最容易拿分的送分题)

目标题目： 1, 2, 6, 7, 8, 9, 10, 11

核心逻辑：

1. 马尔可夫性质 (Markov Property):

- 口诀：“未来只与现在有关，与过去无关。”
- 考点： 。
- 应对题目：
- **Q6:** 选 **C** (未来状态与当前状态之前的状态无关)。注意：有些定义说是“给定当前，未来独立于过去”，Q6选C最贴切，虽然表述有点绕。或者选A/D（取决于具体教材定义，但核心是“无记忆性”）。*更正：标准定义是给定当前状态，未来与过去无关。Q6选C最稳。*
- **Q7:** 选 **B** (无关)。在给定当前状态 时，未来的 就不再依赖过去的 了。

2. 奖励与目标：

- **Reward (奖励):** 是即时的反馈信号（标量）。
- **Return (回报/累计奖励):** 是长期的，RL 的目标是**最大化期望累计奖励** (Expected Cumulative Reward)。
- **折扣因子 γ :**
- $\gamma = 0$: 目光短浅，只看眼前（即时奖励）。
- $\gamma = 1$: 远视，看重未来。
- 应对题目：
- **Q1:** 选 **B** (反馈信号，通常是正向或负向的标量，A太绝对)。注：很多教材定义Reward为标量反馈信号。
- **Q2:** 选 **A** (累计奖励最大化)。这是RL的终极目标。
- **Q8:** 选 **A** (回报等于即时奖励)。因为未来被 γ 了。
- **Q9:** 最优价值函数选的是 **B** (回报最高的动作)，不是即时奖励最高，要看长远。

3. 价值函数与贝尔曼方程：

- $V(s)$ ：状态价值。
- $Q(s,a)$ ：动作价值（在状态s做动作a）。
- **Bootstrap (自举)**：用下一个状态的估计值来更新当前状态的估计值。即 $V(s) \leftarrow V(s) + \alpha (R + V(s') - V(s))$ 。
- 应对题目：
- **Q10**: 选 **C** (状态-动作价值函数)。
- **Q11**: 选 **C** (以模型对后继状态的预测为依据...结合单步回报)。这就是 Bootstrapping 的定义。

第二板块：MC (蒙特卡洛) vs TD (时序差分) (考试重灾区)

目标题目： 12, 13, 14, 16, 17, 18, 20, 21, 22, 43

核心逻辑： (必须死记硬背这个对比表)

特性	MC (Monte Carlo)	TD (Temporal Difference)
更新时机	必须等到回合结束 (Episodic only)	每走一步就能更新 (Step-by-step)
偏差/方差	无偏 (Unbiased), 但方差大 (High Variance)	有偏 (Biased), 但方差小 (Low Variance)
Bootstrap	否 (用真实回报)	是 (用估计值)
环境要求	甚至不需要马尔可夫性也能运作	强依赖马尔可夫性质
收敛性	线性函数下收敛到全局最优	线性函数下 不保证 收敛到全局最优

- **TD(0)**：是 MC 和 TD 的折中。
- 就是 TD(0)（只看一步）。
- 就是 MC（看完全程）。
- **资格轨迹 (Eligibility Traces)**： 是一种实现 TD(0) 的机制，给近期访问过的状态分配权重。

应对题目：

- **Q12**: 选 **C** (MC偏差劣于TD(错)，MC方差优于TD(错)...等等，这里要小心)。
- 正确结论：MC是无偏的（偏差优），方差大（方差劣）。TD是有偏的（偏差劣），方差小（方差优）。
- 看选项：A说MC偏差优(对)方差劣(对)。选 **A**。
- **Q13**: 选 **D** (计算每个状态在n步TD中对**当前局面**的影响权重)。资格迹是分配权重的。
- **Q14**: 选 **D** (时序差分算法)。

- **Q16:** 选 **A** (后向视角是一步计算...所有加权收益)。或者 **B** (通常后向视角即资格迹实现, 比前向更高效/在线)。这题倾向选B或A, 重点是它不用等到最后。
- **Q17:** 选 **C** (2次)。每次访问蒙特卡洛 (Every-visit MC) 每次都会更新。
- **Q18:** 选 **A** γ 。是衰减系数。
- **Q20:** 选 **B** 是错的, A是对的...等等。MC必须等结束, TD不用。所以 **A, B 都不完全对?**
- 重读: Q20 问共同点。
- C: 不需要建立模型 (Model-free)。选 **C**。这是它们最大的共同点。
- **Q21:** 选 **C** (TD有偏, MC无偏)。这是铁律。
- **Q22:** 选 **C** (线性函数下MC收敛到全局最优) 是对的。
- 找错误的: A说非马尔可夫适合TD? 错! TD依赖马尔可夫性, MC不依赖。所以 **A 是错误的**。
- **Q43 (GAE):** GAE (Generalized Advantage Estimation) 本质是 TD() 的一种应用。
- 是 MC (高方差), 是 TD (高偏差)。
- B说 越大偏差越大? 错, 越大越接近 MC, 偏差越小。选 **B**。

第三板块: DQN 与 价值学习 (核心算法)

目标题目: 3, 5, 15, 19, 23, 24, 25, 26, 42

核心逻辑:

1. On-Policy vs Off-Policy:

- **On-Policy (同策略):** “边学边做”, 行为策略 = 目标策略。代表: **SARSA**。
- **Off-Policy (异策略):** “看别人(或过去的自己)做, 自己学”, 行为策略 目标策略。代表: **Q-Learning, DQN**。

2. SARSA vs Q-Learning:

- **SARSA:** (用实际走的下一步 更新)。
- **Q-Learning:** (用下一步最大的可能值更新, 不管实际走了啥)。

3. DQN (Deep Q-Network) 三大板斧:

- **Q-Network:** 输入状态, 输出所有动作的Q值。
- **Experience Replay (经验回放):** 打破数据相关性, 使训练稳定。(Off-policy 才能用)。
- **Target Network (目标网络):** 固定目标Q值的计算网络, 减少震荡。

4. DQN 的改进 (Rainbow):

- **Double DQN:** 解决 **高估 (Overestimation)** 问题。
- **Dueling DQN:** 把 Q 分解为 V (状态价值) + A (优势函数)。
- **Prioritized Replay:** 优先学习 TD-error 大的样本 (难学的样本)。

应对题目：

- **Q3:** 选 **A** (所有动作的价值函数)。DQN输入是State, 输出是每个Action的Q值。
- **Q5:** 行为策略固定不变? 如果是指行为策略和目标策略一直是同一个, 那是On-Policy。如果行为策略固定 (比如一直是随机), 目标策略在变, 那是Off-Policy。
- 这题语境模糊, 但通常“行为策略与目标策略不同/独立”是 Off-policy。如果题目意思是“只用一个固定的策略去跑数据用来学习”, 那通常对应 **B (Off-Policy)** 的场景 (因为在学习过程中策略会变, 但你还在用旧策略的数据)。
- **Q15:** SARSA 的 S 代表 **A (State)**。全称 State-Action-Reward-State-Action。
- **Q19:** 关于 Q-Learning。
- A: Model-free (错)。
- B: 只能处理离散动作 (DQN也是), 连续动作难 (错)。
- C: 用 ϵ -greedy 平衡探索利用 (对)。
- D: 用TD更新, 不是MC (错)。
- **选 C。**
- **Q23:** 关于 DQN 错误的。
- A: 非梯度? 错, 神经网络全是梯度下降。 **选 A。**
- (DQN确实会产生高估现象, 所以有了Double DQN)。
- **Q24:** 关于 DQN 正确的。
- A: Off-policy (对, 但DQN主要是Off-policy)。
- C: 经验回放打破关联 (对)。 **选 C** (这是DQN最核心的特征)。
- **Q25:**
- A: 熵正则通常用于 PPO/Soft Actor-Critic, 不是标准 DQN。
- B: Dueling DQN 是 $V + A$ (对)。 **选 B。**
- **Q26:** Rainbow 不包含哪种?
- Rainbow = DDQN + Prioritized + Dueling + Multi-step + Distributional + Noisy。
- **选 A (Nash DQN)**。这属于多智能体博弈, 不在单体 Rainbow 里。
- **Q42:** 经验回放是什么?
- **选 C** (随机抽样并重复使用)。

第四板块：Policy Gradient & Actor-Critic (进阶核心)

目标题目：4, 29, 30, 31, 35, 36, 37, 38, 44, 45

核心逻辑：

1. Actor-Critic:

- **Actor (演员):** 输出动作 (策略)。
- **Critic (评论家):** 评估动作好不好 (价值函数 或)。
- **AC:** Actor 更新概率, Critic 更新价值。

2. REINFORCE vs AC:

- **REINFORCE:** 基于 MC 的策略梯度 (回合结束才更新, 方差大)。
- **AC:** 引入 Critic (基于 TD) 来减小方差, 但增加偏差。

3. PPO (Proximal Policy Optimization):

- 核心思想: **限制更新步长**, 防止策略改动太大导致崩溃。
- 方法: **Clip** (截断) 目标函数, 或者用 KL 散度惩罚。
- **On-Policy** 算法。

4. DDPG (Deep Deterministic Policy Gradient):

- 用于 **连续动作** 空间。
- **Actor** 输出**确定性动作** (直接输出数值, 不是概率)。
- **Off-Policy** (用经验回放)。
- 加噪声来探索 (Ornstein-Uhlenbeck noise)。

应对题目：

- **Q4:** Actor 负责 **C** (输出动作), Critic 负责 (评估价值)。选 **B 或 C**? 细看:
- A: 模拟环境错。
- B: Actor输出动作, Critic评估价值。选 **B**。
- **Q29:** 哪个不是基于策略(Policy-based)?
- SARSA 是 Value-based (学Q表)。选 **A**。
- REINFORCE, PPO, DDPG 都带策略网络。
- **Q30:** 关于策略梯度。
- C: REINFORCE 没有收敛性保证 (通常认为是对的, 或者说很慢)。
- D: 引入基线(Baseline) **不会** 改变梯度期望(估计值), 只会降低方差。所以 D 错。

- **选 B** (定理将梯度表示为近似公式) 比较稳妥, 或者 **A** (REINFORCE就是直接应用定理)。这题略偏, 建议选 **B** 或 **C**。Baseline作用是减小方差, 不改变偏差, 切记。
- **Q31:** 错误的是?
 - A: Baseline降方差 (对)。
 - B: 换成TD得到AC (对)。
 - C: Critic使用策略梯度? 错, Critic用的是TD误差(均方差)来更新Value。选 **C**。
- **Q36:** PPO 错误的。
 - A: 一阶优化 (对, 即SGD)。
 - B: Penalty是软约束 (对)。
 - C: Clip限制幅度 (对)。
 - D: 不一定单调提升 (PPO理论上是单调提升的改进, TRPO保证单调, PPO近似保证)。但这题里 **A/B/C** 都是明显对的。选 **D** 可能最合适, 因为近似导致无法绝对保证。
- **Q37:** PPO 错误的。
 - A: 共享主干 (对)。
 - B: 是AC架构 (对)。
 - C: 熵正则鼓励探索 (对)。
 - D: 大这个batch仅更新一次? 错! PPO 的特点就是同一个 batch 数据可以 **多次 (Epoch)** 更新! 选 **D**。
- **Q38:** 重参数化 (Reparameterization Trick) 解决什么?
 - **选 A** (随机变量导致梯度无法反向传播)。比如 VAE 或 Soft Actor-Critic 中, 把随机性从采样操作中剥离出来 ($z = \mu + \sigma * \epsilon$)。
- **Q44:** DDPG 错误的。
 - D: 是一种 On-Policy? 错! DDPG 用 Replay Buffer, 是典型的 **Off-Policy**。选 **D**。
- **Q45:** DDPG 正确的。
 - A: 确定性方式探索? 错, DDPG加噪声探索。
 - B: 输出均值方差? 错, 那是随机策略, DDPG输出确定动作值。
 - C: 使用带噪声的探索 (对)。选 **C**。

极速记忆 Cheat Sheet (考前背这个)

1. **DQN = Off-policy + Q-Learning + 经验回放 + 目标网络。**
2. **SARSA = On-policy。**
3. **MC = 无偏、方差大、等回合结束。**
4. **TD = 有偏、方差小、单步更新、Bootstrap。**
5. **** 越大** 越像 MC (方差大, 偏差小)。**
6. **** 越小** 越像 TD (方差小, 偏差大)。**

7. **Actor-Critic:** Actor 动嘴(动作), Critic 打分(价值)。
8. **PPO:** 属于 On-Policy, 核心是 **Clip** (防更新过大), 数据可重复用。
9. **DDPG:** 属于 Off-Policy, 用于 **连续动作**, Actor 输出确定值, 加噪声探索。
10. **分布式:** A3C (异步), IMPALA (Actor-Learner 分离), DD-PPO (分布式PPO)。

必选的30分策略:

先把 **1-11 (基础)** 做完, 再把 **12-22 (MC/TD)** 搞定, 最后在 **23-26, 42-45 (DQN/DDPG)** 里挑你会的。
后面关于 AlphaGo/StarCraft/分布式 的题目, 如果没看过直接选看起来最像人话的或者全选C (通常是这类题的玄学规律), 不要浪费时间思考。

祝你考试顺利! 你只需要这几个核心点就能及格!